Fase 3 – Hipótesis y guión de exposición

1. Hipótesis analíticas para la Fase 4

Cada hipótesis nace de un gráfico del EDA y se evaluará con una de las cuatro técnicas obligatorias, con un criterio de aceptación fijado antes de modelar.

#	Hipótesis	Origen en el EDA	Técnica	Cómo se evalúa	Se acepta si…
H1	Los 365 días se agrupan en al menos 3 perfiles operativos: producción completa, producción reducida y sin producción	Gráficos 1 y 4: laboral ≈ 1,36 t CO2/día, sábado ≈ 0,61 t, domingo y feriados ≈ 0,12 t	Clustering (K-means sobre kpi_diario)	Método del codo y coeficiente de silueta para elegir k; perfil de cada clúster con variables originales	k óptimo ≥ 3 y los 12 feriados caen en el clúster de menor consumo
H2	El clúster de días sin producción tiene el mayor % de intervalos penalizados por reactiva	Gráfico 3: la carga liviana genera el 69 % del costo de penalización	Clustering (perfil de clústeres)	Comparar % penalizado y costo de penalización por clúster	El clúster de menor consumo tiene el % penalizado más alto
H3	Un modelo con variables de calendario supera la regla del reloj (93,3 % de aciertos)	Gráfico 5: hora, mes y día explican el 93,3 % del tipo de carga	Clasificación (regresión logística, Random Forest, kNN)	Accuracy y F1 macro en test frente a la línea base	Accuracy del mejor modelo > 93,3 %
H4	Un modelo solo con variables eléctricas reconoce el tipo de carga mejor que el azar, pero confunde sobre todo Media con Máxima	Gráfico 5B: el consumo de Media y Máxima se traslapa entre 5 y 75 kWh	Clasificación sin variables de tiempo	F1 macro frente a la clase mayoritaria (51,6 %); matriz de confusión	Accuracy > 51,6 % y el par Media–Máxima concentra la mayoría de errores
H5	Dos componentes principales explican al menos el 80 % de la varianza de las 6 variables eléctricas	Gráfico 2: dos grupos de variables muy correlacionadas (r ≥ 0,89 y r =	PCA sobre datos estandarizados	Varianza explicada acumulada y loadings	PC1 + PC2 ≥ 80 %; PC1 ≈ intensidad de producción, PC2 ≈

#	Hipótesis	Origen en el EDA	Técnica	Cómo se evalúa	Se acepta si…
		−0,94)			compensación de reactiva
H6	El factor de potencia y el ratio reactiva/activa son las variables que más separan la carga liviana de las demás	Celda 14: FP mediano 66 % en liviana vs. 92-97 % en media y máxima	LDA como reducción supervisada	Coeficientes del primer eje discriminante; métrica con y sin LDA	FP o ratio Q/P tienen el mayor peso en el eje 1, y la métrica con LDA cae menos de 5 puntos